RAPPORT DE STAGE DE FIN DE TRONC COMMUN EPITA

Refonte du logiciel Coqdoc

 $\begin{array}{lll} \textit{Auteur}: & \textit{Maître de stage}: \\ \textit{François Ripault} & \textit{Yann Régis-Gianas} \\ \textit{francois.ripault@epita.fr} & \textit{yrg@pps.univ-paris-diderot.fr} \end{array}$

<u>Résumé</u>: L'INRIA travaille sur le projet Coq, un assistant de preuve. Au sein de ce projet, le sujet de ce stage consiste en la refonte du logiciel de documentation Coqdoc. L'objectif est de le rendre plus extensible, plus facilement maintenable et mieux l'intégrer au sein du projet.

Stage effectué à $\mathbf{L'INRIA}$ du : 3 Septembre 2012 au 11 Janvier 2013







Table des matières

1	Inti	oduction	1			
	1.1	Contexte du stage	2			
	1.2	Problématique du stage	3			
	1.3	Motivations et perspectives	4			
		1.3.1 Validation des acquis de tronc commun	4			
		1.3.2 Introduction au monde de la recherche	4			
	1.4	Phases de déroulement et introduction du rapport	5			
2	Pré	entation de l'entreprise	6			
	2.1	Le secteur d'activité	7			
	2.2	L'entreprise	8			
		2.2.1 Présentation générale	8			
		2.2.2 Les missions de l'INRIA	8			
		2.2.3 Organisation	9			
	2.3	Le service	12			
		2.3.1 Le laboratoire Preuves, Programmes et Systèmes	12			
		2.3.2 Thématiques de recherche du laboratoire	12			
		2.3.3 L'équipe πr^2	13			
	2.4	Le positionnement du stage dans les travaux de l'entreprise .				
3	Tra	ail effectué	16			
	3.1	Le cahier des charges	17			
		3.1.1 Logiciels de documentation	17			
		3.1.2 Analyse de l'existant : Coqdoc	19			
		3.1.3 Analyse de l'existant : Coq-tex	22			
		3.1.4 But général : refonte de Coqdoc	25			
	3.2	Compte-rendu d'activité	26			
		3.2.1 Présentation des outils utilisés	26			
		3.2.2 Conception de l'architecture du logiciel	26			
		3.2.3 Traitement du langage d'entrée	29			
		3.2.4 Interactions avec l'interprète	32			
		3.2.5 Extension du protocole d'interaction	34			
		3 2 6 Traitement du code annoté	30			

		3.2.7	Gestion des identifiants	4	
		3.2.8	Génération des documents finaux	4	
		3.2.9	Extension de Coqdoc pour Coq-tex	4	
	3.3	.3 Interprétation et critique des résultats			
		3.3.1	Version préliminaire de Coqdoc stable	4	
		3.3.2	Extensibilité du logiciel	4	
		3.3.3	Perspectives d'évolution du logiciel	4	
5	We	bograpl	hie	4	
5		bograpl nexes	hie		
		nexes	hie	4	
	Ani 6.1	nexes Somma		4	
	Ani 6.1	nexes Somma	ire des Annexes	4 4	
	Ani 6.1 6.2	nexes Somma Docum 6.2.1	nire des Annexes	4 4 4 4	
	Ani 6.1 6.2	nexes Somma Docum 6.2.1 Docum	aire des Annexes		

Chapitre 1

Introduction

Le présent rapport détaille travaux effectués au cours du stage de fin de tronc commun à l'EPITA, réalisé du 3 Septembre 2012 au 11 Janvier 2013.

Le sujet du stage consiste en la refonte complète du logiciel de documentation **Coqdoc**.

1.1 Contexte du stage

Ce stage s'est déroulé au sein de l'INRIA, plus particulièrement dans l'équipe πr^2 .

L'INRIA est l'institut national de recherche en informatique et en automatique. C'est un établissement public à caractère scientifique et technologique, qui est l'acteur principal de la recherche en informatique en France.

Je fus intégré à l'équipe πr^2 appartenant au laboratoire Preuves, Programmes et Systèmes.

Le laboratoire **Preuve**, **programmes et systèmes** est une unité mixte de recherche, rattachée à plusieurs établissements scientifiques (INRIA, CNRS, et l'université Paris Diderot), qui regroupe à la fois des chercheurs en informatique et en logique mathématique, au sein d'une même thématique, celle des langages de programmation, des systèmes distribués, et de leurs fondements logiques.

Au sein de ce laboratoire, l'équipe πr^2 se concentre sur la recherche autour de la correspondance entre preuves et programmes, ayant donné naissance à l'assistant de preuves \mathbf{Coq} , et le formalisme qui sous-tend l'implémentation d'un tel logiciel.

Ce stage fut effectué sous la direction de **Yann Régis-Gianas**, maître de conférence à l'université Paris Diderot, et chercheur au sein du laboratoire πr^2 .

1.2 Problématique du stage

L'objectif de ce stage est de refaire le logiciel de documentation de l'assistant de preuves \mathbf{Coq} , ne répondant plus aux attentes de ses utilisateurs. En effet, bien que celui-ci remplisse correctement sa tache il souffre d'un manque crucial d'extensibilité et s'intègre mal dans la suite d'outils fournie avec \mathbf{Coq} . Il s'agit donc de refaire entièrement \mathbf{Coqdoc} afin de mieux l'intégrer dans \mathbf{Coq} , tout en concevant une architecture qui permette de l'étendre facilement par la suite.

1.3 Motivations et perspectives

Le stage offre des perspectives très intéressantes en relation directe avec mes objectifs professionnels, tout en mettant en application les compétences que j'ai acquises au cours du cycle de tronc commun.

1.3.1 Validation des acquis de tronc commun

Le projet proposé met en jeu des compétences propres au métier d'ingénieur. En effet, la conception d'un nouveau logiciel est en relation directe avec les enseignements de l'EPITA :

- Conception d'un logiciel : le stage a pour but la réécriture à neuf d'un logiciel préexistant : Coqdoc. L'objectif est de créer un outil s'intégrant bien dans la suite Coq, palliant aux problèmes de l'outil précédent, mais également en réutilisant les éléments intéressants pour la nouvelle version de Coqdoc.
 - La conception d'un nouveau logiciel permet de mettre en application les compétences de programmation mais également des aspects annexes concernant le développement de projet, telle que la documentation du code ou la réalisation de tests unitaires.
- Gestion de projet : Écrire un nouveau logiciel apporte également des problématiques concernant la gestion de ce projet : il faut choisir un cycle de développement approprié permettant dans le temps du stage, de réaliser l'application. Il s'agit également de répondre aux attentes des utilisateurs concernant le projet, et de faciliter l'intégration du logiciel au sein de la suite d'outils Coq.

1.3.2 Introduction au monde de la recherche

Ce stage représente également une bonne introduction aux problématiques de recherche abordées dans le domaine de l'équipe πr^2 .

En effet, bien que le sujet de stage mette en jeu des compétences surtout liées au domaine de l'ingénierie, le contexte scientifique du stage me permet de découvrir les problématiques de recherche dans le laboratoire PPS et plus particulièrement l'équipe de recherche πr^2 .

Cela répond directement à mes objectifs professionnels puisque après l'EPITA, j'ai l'intention de poursuivre dans le monde de la recherche. Ce stage me permet donc de valider cet objectif professionnel, tout en tissant des liens avec les scientifiques travaillant dans ce domaine.

1.4 Phases de déroulement et introduction du rapport

Ce rapport retrace les différentes phases de déroulement du stage :

- la prise de connaissance des problématiques à résoudre
- la conception du logiciel de documentation
- l'implémentation de ce logiciel

Une première partie présentes les différentes structures au sein desquelles s'est effectué mon stage, ainsi que l'intégration des réalisation de ce stage dans les travaux de l'entreprise.

Dans une deuxième partie, nous analysons l'existant et définissons la méthodologie et les objectifs du stage.

La troisième partie détaillera la phase de réalisation technique.

Enfin, dans une dernière partie, nous offrons une analyse critique des résultats de ce stage.

Chapitre 2

Présentation de l'entreprise

Le stage proposé s'est fait au sein de l'équipe πr^2 , appartenant au laboratoire PPS, regroupant des chercheurs de plusieurs instituts de recherche. Cette section présente l'institut de recherche qui m'a employé ainsi que le laboratoire PPS, pour enfin présenter l'équipe πr^2 .

2.1 Le secteur d'activité

L'INRIA est un acteur majeur de la recherche informatique, aussi bien en France qu'à l'international.

Les activités de recherche de l'INRIA sont regroupées en 5 thèmes qui visent à décrire une **activité scientifique** très large :

- Mathématiques appliquées, calcul et simulation
- Algorithmique, programmation, logiciels et architectures
- Réseaux, systèmes et services, calcul distribué
- Perception, cognition, interaction
- STIC pour les sciences de la vie et de l'environnement

L'INRIA travaille avec de nombreux **partenaires industriels**. Les principaux partenaires sont les suivants :

- Alcatel-Lucent
- EDF R&D
- STMicroelectronics
- Bull
- Andra
- Microsoft-research

L'institut ne se contente pas uniquement de collaborations avec l'industrie, c'est également un créateur **Start-up**, qui commercialisent des produits issus des prototypes de recherche, et du savoir-faire de l'INRIA

L'INRIA possède également de nombreux partenariats à l'international, tant avec des universités mondialement reconnues qu'avec des sociétés multinationales.

2.2 L'entreprise

2.2.1 Présentation générale

La fondation d'INRIA remonte à 1967 sous le nom de IRIA (Institut de recherche en informatique et en automatique). L'IRIA est devenu l'Institut national de recherche en informatique et en automatique (INRIA) en 1979. L'INRIA est placé sous la double tutelle du ministère de la recherche et du ministère de l'économie, des finances et de l'industrie.

INRIA est signataire du Pacte PME depuis le 17 décembre 2008, et l'institut participe à l'espace européen de la recherche à travers le consortium ERCIM¹, dont il a été l'un des membres fondateurs en 1989.

L'INRIA a pour vocation d'entreprendre des recherches fondamentales et appliquées dans les domaines des sciences et des technologies de l'information et de la communication (STIC). L'institut assure également un fort transfert technologique en accordant une grande attention à la formation par la recherche, à la diffusion de l'information scientifique et technique, à la valorisation, à l'expertise et à la participation à des programmes internationaux. Jouant un rôle fédérateur au sein de la communauté scientifique de son domaine et au contact des acteurs industriels, l'INRIA est un acteur majeur dans le développement des STIC en France.

L'INRIA est actif au sein d'instances de normalisation comme l'IETF ², l'ISO ³ ou le W3C ⁴ dont il a été le pilote européen de 1995 à fin 2002. Enfin l'institut entretient d'importantes relations internationales : en Europe, l'INRIA s'implique fortement dans le 6ème PCRDT ⁵ où il participe à plus de 40 actions ainsi que dans le consortium ERCIM, qui regroupe 17 organismes de recherche. A l'international, l'institut collabore avec de nombreuses institutions scientifiques via plusieurs laboratoires de recherche conjoints (LIAMA ⁶, PPS), les équipes de recherche associées, et différents programmes de coopération.

2.2.2 Les missions de l'INRIA

Les grandes missions de l'INRIA se résument dans les points suivants :

- $1. \ \ Consortium \ de \ recherche \ européen \ pour \ l'informatique \ et \ les \ math\'ematiques$
- 2. Internet engineering task force
- 3. Organisation internationale de normalisation
- 4. Worldwide web consortium
- 5. Programme Cadre de Recherche et Développement Technologique
- 6. Laboratoire Franco-Chinois d'informatique, d'automatique et de mathématiques appliquées

- Concevoir et maîtriser les futures infrastructures des réseaux et des services de communication
- Développer le traitement des informations et données multimédia
- Garantir la fiabilité et la sécurité des systèmes à logiciel prépondérant
- Coupler modèles et données pour simuler et contrôler les systèmes complexes
- Combiner simulation, visualisation et interaction
- Modéliser le vivant
- Intégrer pleinement les STIC dans les technologies médicales

2.2.3 Organisation

L'organisation de l'INRIA est établie par le décret du 2 août 1985. L'institut est dirigé par un conseil d'administration, dont son président, assure également les fonctions de directeur général. Il peut s'appuyer sur les compétences de deux instances scientifiques :

- le conseil scientifique, instance de réflexion et de proposition de l'institut en matière de politique scientifique,
- la commission d'évaluation, instance chargée de procéder à l'évaluation des équipes de recherche et des personnels scientifiques et qui contribue à définir les orientations des activités de l'institut.

Le conseil d'administration regroupe :

- Un membre de droit : le directeur général du Centre national de la recherche scientifique ou son représentant.
- 7 représentants de l'état désignés respectivement par les ministres chargés de la recherche, de l'industrie, du budget, de l'enseignement supérieur, de la défense, des relations extérieures et des télécommunications.
- 8 personnalités : deux personnalités de l'industrie de l'informatique et de l'automatique, deux personnalités scientifiques, deux personnalités représentatives du monde du travail, deux personnalités choisies parmi les utilisateurs de l'informatique et de l'automatique désignées par le ministre chargé de l'industrie.
- 4 représentants du personnel de l'institut ou leurs suppléants dont deux chercheurs, élus pour une durée de quatre ans renouvelable une fois, selon des modalités fixées par arrêté du ministre chargé de la recherche et du ministre chargé de l'industrie.

L'INRIA en chiffres

L'INRIA est structuré en 6 unités de recherche à travers la France : Rocquencourt et son antenne Parisienne, Rennes, Sophia Antipolis, Grenoble,

Nancy, Bordeau, Lille, Saclay, Marseille, Lyon et Metz.

En tout, ces sites regroupent (données de février 2011) :

- 4200 personnes, dont 2500 rémunérées par l'INRIA
- 3150 scientifiques : 1200 doctorants, 250 post-doctorants et 600 ingénieurs R&D
- 300 stagiaires

Au sein de ces scientifiques, on compte notamment :

- 6 membres de l'académie de sciences
- 16 lauréats du conseil européen de la recherche

Les chiffres clefs de la recherche scientifique à l'INRIA :

- 200 équipes projets
- 67 équipes associées, de dimension internationale
- 4500 publications scientifiques
- 24 conférences internationales
- 105 projets européens dans lesquels s'implique l'INRIA

Les chiffres pour les partenariats avec l'industrie :

- 230 brevets en activité
- 100 entreprises crées par l'institut

L'INRIA bénéficie d'un budget de 231 M€ dont 125,8 M€ alloués à la recherche (54% du budget) (chiffres pour l'année 2011). La prévision de recette pour l'année 2011 étant de 227,6M€, cela en fait un institut de recherche presque autosuffisant.

L'organigramme figure 2.1 présente les différents services de l'INRIA ainsi que leur directeurs respectifs

Organigramme d'Inria



FIGURE 2.1 – Organigramme des différents services de l'INRIA

2.3 Le service

Cette section présente le laboratoire PPS. Ce n'est pas à proprement parler un service de l'INRIA, car c'est un groupe de recherche multidisciplinaire regroupant des chercheurs de divers horizons, et de plusieurs structures de recherche.

2.3.1 Le laboratoire Preuves, Programmes et Systèmes

PPS est un laboratoire qui regroupe les chercheurs venant de l'informatique et de la logique mathématique autour de l'idée que la logique et d'autres champs des mathématiques peuvent permettre d'élucider le sens de programmes, d'améliorer leur sûreté et réciproquement, que l'informatique est une source permettant aux mathématiques d'avancer.

La majorité de la recherche menée par PPS gravite autour la correspondance de Curry-Howard : l'équivalence entre preuve et programmes, transformant le λ -calcul 7 en un outil utilisé pour établir des preuves mathématiques. Réciproquement, le savoir de la logique mathématique devient un élément de réponse pour les problèmes posés par l'industrie dans le domaine de l'informatique.

2.3.2 Thématiques de recherche du laboratoire

Les thématiques du laboratoire peuvent être regroupées en six directions principales :

- Jeux et modèles de la programmation :
 - Les modèles de jeux permettent de modéliser mathématiquement l'interaction d'un programme avec son environnement. Ce champ de recherche débouche aujourd'hui sur des outils d'analyse et de certification des programmes
- Théorie de la démonstration et λ-calcul : Ce domaine d'étude se concentre sur le développement de l'assistant de preuve Coq et les champs de recherche qui lui sont associés, tels que le calcul des constructions inductives.
- Spécifications et réalisabilité: L'objectif est, à partir d'un théorème mathématique, de trouver le programme équivalent. L'approche particulière de ce domaine est qu'au lieu de supposer une formule avant la preuve, la théorie de la réalisabilité considère les formules comme faisant partie des spécifications d'un programme.

^{7.} Le λ -calcul est un formalisme mathématique qui constitue les fondements des langages de programmations du paradigme fonctionnels

• Réécriture : La théorie de la réécriture combine des éléments de la logique, de l'algèbre, du λ-calcul, etc . . ., et a pour but de transformer des programmes (et plus précisément des objets syntaxiques) à travers l'application de règle bien déterminées. Cette théorie propose un formalisme permettant de modéliser à la fois des langages fonctionnels, impératifs ou encore orientés objet. Les applications d'une telle théorie sont très diverses : la plus connue étant probablement l'optimisation d'un programme par le compilateur par le moyen de la réécriture de code. La théorie de la réécriture permet de formaliser et de prouver ces mécanismes.

• Programmation:

Le laboratoire développe de nouvelles méthodes de programmations appliquées à de nombreux domaines qui vont des protocoles réseaux jusqu'au web. Ces développements sont étroitement liés à la logique mathématique, et permettent de mettre en évidence des propriétés sur ces programmes ⁸.

• Logique, Concurrence et Modélisation :

Un nouveau front de recherche s'est récemment ouvert à PPS, autour de la modélisation de la programmation dite concurrente (calculs de processus) et mobile, qu'il s'agisse d'en rechercher les fondements logiques, ou de les appliquer à une troisième science : la biologie, et plus précisément à la modélisation des processus de la biologie moléculaire.

2.3.3 L'équipe πr^2

L'équipe πr^2 est composée de chercheurs faisant partie du laboratoire PPS, mais également de scientifiques appartenant à l'université Paris-Diderot ou l'INRIA.

Ses sujets de recherche sont les suivants :

- La recherche fondamentale autour de la correspondance entre preuve et programmes
- La recherche théorique autour du formalisme qui sous-tend les mécanismes de l'assistant de preuves Coq
- Un domaine d'implémentation : Coq, notamment en le considérant comme un langage de programmation avec des types-dépendants.

L'équipe développe notamment deux logiciels, Coq (présenté ci-après), et Pangolin, qui lui permet la certification de programmes fonctionnels.

L'assistant de preuves Coq

Le logiciel Coq est un outil de développement semi-interactif de preuves bâti autour d'un langage de programmation fonctionnelle fortement typé.

 $^{8.\} Par$ exemple, le framework de développement web Ocsigen, donne la garantie de générer des pages web valides selon les standards W3C

Développé conjointement par plusieurs équipes INRIA et hors INRIA, Coq est utilisé tant pour la formalisation des mathématiques que pour la certification de propriétés de programmes. Naturellement doté de types dépendants, Coq a une carte à jouer comme langage de programmation à type riches. Un des objectifs de πr^2 dans ce cadre est le développement de bibliothèques de programmation certifiée, la certification du processus d'extraction de programme Coq vers des langages fonctionnels comme Objective Caml, ainsi que le développement de nouvelles méthodes de preuves pour Coq.

Les principaux champs d'applications de Coq sont les suivants :

- L'écriture de programmes certifiés : les systèmes critiques (les transports, l'énergie, la santé, les télécommunications, la cryptologie, etc ...) ont besoin d'être rigoureusement conforme à leur spécification, pour pouvoir éviter tout disfonctionnement du logiciel. La preuve de programme consiste à s'assurer mathématiquement que le comportement d'un programme est conforme à ce qui est attendu, et Coq facilite ce travail de preuve de programme.
- La validation de preuves mathématiques : les publications scientifiques dans le domaine des mathématiques incluent parfois des preuves de plusieurs centaines de pages. Coq est un outil permettant de valider les preuves ainsi publiées. On peut citer le théorème de Fermat-Wiles ou encore Feit-Thompson comme exemples de cette application.
- Dans la recherche fondamentale en Informatique : c'est un outil qui permet de formaliser (et valider) la sémantique des langages de programmation et, qui est utilisé plus largement dans la théorie des langages de programmation.

2.4 Le positionnement du stage dans les travaux de l'entreprise

L'utilisation d'un logiciel de documentation est très importante lors du développement d'un projet. Au sein du développement de Coq, Coqdoc possède plusieurs cas d'utilisations qui en font un outil très utilisé, et dont l'amélioration est supposée offrir plusieurs avantage. La liste suivante présente les différents cas d'utilisations de Coqdoc dans le projet :

• Documentation de développement du compilateur :

Bien qu'une importante partie de Coq soit écrit en Caml, l'ensemble des bibliothèques standards, c'est à dire les outils pour Coq fournis avec le compilateur, sont écrites en Coq. Coqdoc permet donc de décrire le fonctionnement d'une importante partie du code source du compilateur.

• Documentation utilisateur :

Une importante partie de la documentation explique le fonctionnement du projet Coq à l'utilisateur. Dans une documentation utilisateur, le code sert d'exemple aux explication fournies par la documentation.

• Écriture de documents :

Cette application se distingue de l'écriture de documentation car elle n'est pas directement associée à un code source. L'objectif ici est d'inclure les avantages de Coqdoc (coloration syntaxique, mise en forme du code) dans des documents qui ne sont pas directement liés au compilateur, tels que des articles scientifiques ou des livres.

Coqdoc possède donc une grande importance au sein du projet Coq. La reconception de ce logiciel doit permettre d'offrir des fonctionnalités qui impacteront l'ensemble de ses utilisateurs.

Chapitre 3

Travail effectué

Cette section détaille le travail effectué au cours de ce stage de fin de tronc commun. Nous détaillons tout d'abord les objectifs à atteindre en présentant les outils utilisés, et en expliquant les spécificités propre à ce stage. Nous expliquons ensuite les différentes phases de la conception du logiciel, et les phases du développement. Enfin, nos offrons une analyse critique des résultats que nous avons obtenus à l'issue de ce stage de fin de tronc commun.

3.1 Le cahier des charges

Cette section détaille les objectifs du stage à travers une analyse des outils existants (plus précisément, "l'ancien" Coqdoc, et Coq-tex), et nous détaillons les objectif à atteindre pour le nouveau Coqdoc.

3.1.1 Logiciels de documentation

Lors du développement d'un logiciel, le code source est souvent insuffisant pour détailler le fonctionnement du programme, car il manque en clarté et n'est pas toujours assez explicite. Le rôle de la documentation est de décrire les différents aspects du fonctionnement attendu du code source. Cette documentation est incluse dans les fichiers sources sous forme de commentaires, de façon à ce qu'elle soit facilement accessible aux développeurs.

Le rôle d'un logiciel de documentation est d'extraire ces informations contenues dans le code source afin d'en constituer un guide de référence ou un manuel, sous forme de pages web ou de documents PDF. Cela permet au programmeur de bénéficier d'un document décrivant clairement le projet, et qui détaille les fonctionnalités accessibles au programmeur.

L'utilisation d'un générateur de documentation possède plusieurs intérêts :

• Facilité de mise à jour de la documentation :

Parce que la documentation est située dans le code source, lorsqu'un développeur modifie un fichier, il peut facilement mettre à jour cette documentation. Ainsi, le manuel de référence associé au code source évolue en même temps que celui-ci.

• Mise en forme automatique de documents :

Les logiciels de documentation possèdent des règles de mise en forme des commentaires dans les documents produits. Ainsi, un générateur de documentation sait traiter les informations de mise en forme données par le programmeur, pour avoir une meilleure explication du code source (découpages logiques, titres, mettre en gras les éléments importants dans les commentaires).

• Variété des formats de sortie :

Enfin, l'un des éléments les plus important est le fait qu'un logiciel de documentation sait gérer plusieurs formats de sorties pour la documentation, allant de la génération de pages web à la génération de PDF.

Les exemples figures 3.1 et 3.2 présentent un morceau de code documenté, et le rendu généré par coqdoc.

```
(** Ceci est une section de commentaire.
   La ligne suivante définit une variable *)
Definition maVariable : Set.
(* Ceci est un commentaire n'apparaissant pas dans la documentation, il ne commence que par une seule étoile.*)
```

FIGURE 3.1 – Exemple de fichier d'entrée donné à Coqdoc

Ceci est une section de commentaire. La ligne suivante definit une variable Definition maVariable : Set.

FIGURE 3.2 – Exemple de rendu généré par Coqdoc à partir de la figure 3.1

3.1.2 Analyse de l'existant : Coqdoc

Le projet Coq avait déjà un logiciel de documentation de son code source. Cette section détaille les particularités de ce logiciel. L'un des objectifs du stage était d'avoir un nouveau Coqdoc dont le comportement est le plus proche possible de l'ancien : il doit pouvoir gérer les mêmes options et un rendu similaire. Cela permet de :

- Faciliter l'intégration du nouveau logiciel grâce à la rétro-compatibilité
- Avoir un rendu similaire par rapport aux pages de documentations générées auparavant
- Se servir de l'ancien logiciel comme référence pour un ensemble de tests fonctionnels et techniques

Format des fichiers d'entrée

Comme beaucoup de logiciels de documentation, Coqdoc propose un langage de mise en forme de la documentation : ce sont des balises, qui, en étant présentes dans le code source, permettent de mettre en forme le fichier de sortie, et qui permettent de donner de plus amples informations à propos du code documenté.

Format des lignes de documentation:

Comme nous l'avons déjà vu, Coqdoc fait une distinction entre commentaires et documentation. En Coq, les commentaires sont préfixés par "(*" et se terminent par "*)". Coqdoc considère que tout commentaire commençant par "(**" est une portion de texte devant apparaître dans la documentation générée.

Titres:

Pour introduire des titres dans le document de sortie, l'utilisateur peut préfixer le début d'une ligne par 1 à 4 astérisques suivies d'une espace. Le nombre d'astérisques déterminant le niveau d'importance du titre.

Listes:

Toute ligne commençant par un tiret et précédée de **n** espaces est un élément d'une liste, dont le niveau de profondeur est déterminé par le nombre d'espaces

Séparateur horizontal:

Une ligne constituée uniquement de 4 tirets ou plus produit un séparateur horizontal

Emphase:

Il est possible de mettre en valeur des mots en les encadrant de tirets bas ("_").

Verbatim:

On peut inclure du code dans de la documentation en encadrant cette portion de code de double chevrons (<< et >>)

Cacher des portions de code :

A des fins de clarté dans la documentation, on peut cacher (ou afficher) des portions de code avec les délimitant avec (* begin hide *) et (* end hide *) (pour forcer l'affichage, il suffit de remplacer hide par show)

Règles de traduction:

L'utilisateur peut définir des règles de traduction avec le mot clef printing, avec les délimiteurs suivants

- \cdot # pour une sortie HTML
- · % pour une sortie en LaTeX
- · \$ pour une notation mathématique en sortie LaTeX

Le listing 3.1 donne un exemple de ces règles de mise en forme dans le fichier d'entrée

Listing 3.1 – Exemple des règles de mise en forme de Coqdoc

```
(** * Ceci est un titre de niveau 1
Les lignes qui suivent sont une liste
- Un premier élément
- Un second élément :
    - Une sous liste d'un seul élément
- Le dernier élément de cette liste
La ligne suivante produit un séparateur horizontal :
Nous pouvons également mettre une emphase sur certains _mots_.
Ainsi qu'insérer des règles de formattages spécifiques au
fichier de sortie :
\% en \latex \% $ en notation mathématique $ # en html #
Nous pouvons également introduire des portions de code dans la
documentation :
<<
  Definition maVariable : Set.
>>
La portion de code qui suit sera cachée dans le fichier de
sortie *)
(* begin hide *)
Definition maVariable2 : Set.
(* end hide *)
(** Enfin, nous pouvons ajouter des règles pour transformer
certains caractères dans le fichier de sortie grâce au mot clef
printing : *)
(** printing -> %\ensuremath{\rightarrow}% *)
```

Format des fichiers de sortie:

Le rôle de Coqdoc est d'effectuer une traduction du format d'entrée précédemment présenté vers plusieurs formats de sortie. Au cours de cette traduction, Coqdoc prends en compte les règles de mise en forme données en entrée pour la documentation et fait une analyse syntaxique du code source.

La liste suivante détaille les différentes caractéristiques de Coqdoc dans la génération des fichiers de sortie

• Mise en forme de la documentation

La première étape est la traduction des informations de mise en forme contenues dans la documentation. Le rôle de Coqdoc ici est de générer les balises adéquates dans le format de sortie

• Analyse syntaxique du code source

Coqdoc a également pour rôle de mettre en forme le code source des fichiers lus en entrée. Pour cela il effectue une analyse syntaxique des sections de code source, et met en forme ces éléments de code source dans le fichier de sortie, en effectuant :

- 1. Une coloration syntaxique du code
- 2. Le pretty print de certains symboles selon les règles de traduction par défaut, et également selon celles définies par l'utilisateur. Par exemple, l'ancien coqdoc traduit automatiquement le symbole → en →. Le tableau section 6.3.1 donne une liste exhaustive des symboles traduits par coqdoc.

• Gestion de la structure logique de la documentation

Coqdoc doit également gérer les règles de génération des fichiers selon la volonté de l'utilisateur. Ceci est fait avec des options passées à Coqdoc, qui permettent de définir si un seul fichier doit être généré (pour un manuel de référence par exemple) ou plusieurs (pour une documentation utilisateur). Il y a également des règles par défaut selon le format de fichier de sortie : par exemple, pour une sortie HTML, plusieurs fichiers seront générés, tandis qu'une sortie en LaTeX entraînera la génération d'un seul fichier mettant en commun tous les fichiers d'entrée.

• Génération des liens hypertextes

Une autre partie du travail de Coq est la génération des liens hypertextes, qui permettent de faire référence à :

1. Des identifiants déclarés dans d'autres fichiers : en effet, l'utilisateur fournit souvent plusieurs fichiers à documenter, et un identifiant peut avoir une importance dans plusieurs fichiers. Cette génération de liens permet de faciliter la lecture de la documentation, en proposant un lien vers la déclaration de l'identifiant, pour permettre à l'utilisateur d'obtenir de plus amples informations à propos de celuici si nécessaire.

Cette génération de liens se base sur des fichiers issus de la compilation ayant pour extension .glob qui détaille les identifiants déclarés dans un fichier. Grâce à ceux ci, Coqdoc peut ainsi générer des références entre plusieurs fichiers.

- 2. Coqdoc propose également de générer des références à la documentation de la bibliothèque standard; cela permet de fournir à l'utilisateur un moyen rapide de s'informer sur un élément faisant partie du langage Coq.
- 3. De la même manière, il est possible de faire **référence à une bibliothèque externe**, pour pouvoir détailler de celle-ci avec le projet documenté.

Nécessités d'amélioration

Nous détaillons dans cette section les raisons qui motivent la refonte du logiciel Coqdoc :

• Conception du logiciel :

La conception de Coqdoc rend difficile son maintien. C'est un logiciel qui manque de structure logique et dont la conception souffre de plusieurs défauts. Une refonte permettrait d'avoir une structure logique plus cohérente, et faciliterait le maintien d'un tel outil.

• Extensibilité :

Coqdoc possède un manque important d'extensibilité. Un tel outil bénéficierait d'une plus grande variété de cas d'utilisation qui gravitent autour du même concept de présentation de code et de mise en forme d'une documentation autour. On peut par exemple citer la génération d'une documentation interactive, où l'on peut rejouer les preuves Coq dans le navigateur internet.

• Redondance de certains éléments logiciels :

Coqdoc fait une analyse de code source, et celle-ci est faite par de nombreux outils dans la suite logicielle de Coq (le compilateur, l'éditeur Co-qIDE, Coq-tex). La redondance de ces éléments peut être retirée en réécrivant Coqdoc, et en proposant une interface unifiée.

3.1.3 Analyse de l'existant : Coq-tex

Un des autres objectifs de ce stage était d'offrir un remplacement pour Coqtex, un des autres outils du projet Coq. Nous détaillons dans une première partie l'approche qu'offre Coq-tex à propos de la programmation, pour ensuite détailler son fonctionnement.

Programmation lettrée

La programmation lettrée (literate programming) est une approche de la programmation introduite par **Donald Knuth** dans laquelle le code source du programme suit le flux de pensée de l'auteur : à la manière d'un article, le programmeur introduit les concepts de son programme dans l'ordre logique de la pensée humaine, au lieu de suivre l'ordre logique et la manière demandée par le compilateur. A travers un ensemble de fonctions (ou plutôt de macros), l'auteur peut cacher l'abstraction demandée par l'ordinateur pour s'exprimer dans un langage plus proche du langage naturel.

Ainsi les outils pour la programmation lettrée permettent de générer deux versions d'un code source : une nouvelle version du code adaptée à la génération d'un **programme** par un compilateur, et une autre version qui elle est sous la forme d'une **documentation** à destination d'un lecteur.

Cette approche est particulièrement intéressante pour expliquer des programmes Coq car elle permet de changer l'ordre logique des différents éléments du programme pour ainsi avoir une version plus facile à comprendre pour des humains : la preuve de théorèmes mathématiques en Coq peut ainsi être plus facile à comprendre pour un lecteur, et à partir du programme fournissant la preuve, il est possible d'obtenir un article scientifique expliquant cette preuve.

Fonctionnement de Coq-tex

Coq-tex est un outil se rapprochant de ce concept de programmation lettrée. Le programme prend en argument un fichier LaTex, et extrait les phrases Coq contenues dans celui-ci, pour y insérer à la place le résultat de leur interprétation.

La production d'un document LaTeX bénéficie ainsi d'une phase d'interprétation du code Coq contenu dans ce document, pour pouvoir fournir le résultat de l'interprétation de code avec une version récente de l'interprète Coq. Cet outil est notamment utilisé pour générer la documentation officielle du projet Coq.

Le fonctionnement de Coq-Tex gravite autour de 3 environnements 1 insérés dans un fichier LaTeX. La liste suivante détaille le comportement de chacun :

• coq_example:

Le code contenu dans ces balises sera extrait et évalué par l'interprète

^{1.} Un environnement en LaTeX est une portion de code entourée des balises \begin{environnement} et \end{environnement}, où environnement est le nom de l'environnement. Le texte contenu dans ces balises sera ainsi traité selon le type d'environnement dans lequel il est inclut.

phrase par phrase. Chacune de ces phrases sera copiée dans le fichier de sortie, et sera suivie du résultat de son interprétation.

• coq_example*:

Le code contenu dans ces balises sera extrait et interprété, et il sera recopié dans le fichier de sortie. Cependant, les réponses de l'interprète seront ignorées.

• coq_eval:

Les phrases contenues dans l'environnement coq_eval seront évaluées silencieusement. Seulement le résultat de leur évaluation sera inclut dans le document de sortie.

Facilité de fusion avec Coqdoc

Coq-tex reprend la même idée que Coqdoc dans le sens où ces deux outils ont un rôle de traduction : ils prennent un document d'entrée pour effectuer une évaluation de certaines portions du code contenues dans celui-ci, afin de générer un document mis en forme.

Ainsi ces deux outils ont des rôles de documentation du code source, et partagent d'importantes similarités dans leur fonctionnement. Une fusion de ces deux outils apparaît donc comme logique puisqu'elle facilitera ainsi la maintenance de l'outil, et regroupera des sections logique qui auparavant étaient dupliquées dans deux programmes.

Intégrer cet outil dans Coqdoc permet également d'enrichir Coq-tex, en permettant à l'utilisateur de profiter de la diversité des formats de sortie de Coqdoc et en rajoutant les caractéristique de l'outil Coq.

3.1.4 But général : refonte de Coqdoc

Les sections précédentes on démontré le besoin de réécrire le logiciel Coqdoc. La majeure partie de mon stage s'est concentrée sur la conception et la réécriture de ce logiciel.

Nous rappelons brièvement les objectifs introduit dans les sections précédentes concernant le logiciel produit pendant ce stage :

- Le nouveau Coqdoc doit avoir un comportement le plus proche possible de l'ancien Coqdoc.
- Il doit également remplacer Coq-tex, l'outil de programmation lettrée.
- L'attention doit être portée sur une architecture extensible, qui permette aux développeurs de rajouter de nouveaux comportements et d'enrichir le logiciel.

En arrivant dans ce stage, j'avais également plusieurs objectifs personnels que je désirais réaliser dans ce stage.

Tout d'abord, améliorer mes compétences dans le langage de programmation OCaml (une présentation du langage est incluse ci-après), qui est un langage dont les spécificités m'intéressent beaucoup.

Une autre aspect était de découvrir les sujets de recherches au sein de l'équipe πr^2 , et de voir si les sujets explorés m'intéressaient.

Enfin, le sujet de ce stage me permet également de valider les acquis de ma formation à travers la conception et l'écriture d'un logiciel complexe.

3.2 Compte-rendu d'activité

Nous détaillons dans cette section les différents aspects du développement de Coqdoc au cours de ce stage. Nous introduisons tout d'abord les outils utilisés, puis nous détaillons la phase de conception du logiciel, tout d'abord l'architecture générale puis les choix techniques de cette conception. Enfin, nous détaillons chaque étape du développement de Coqdoc au cours du stage.

3.2.1 Présentation des outils utilisés

Le choix du langage s'est naturellement porté sur OCaml pour le développement de Coqdoc, et cela pour plusieurs raisons. La liste suivante détaille les différents avantages à utiliser OCaml :

• Langage du compilateur Coq:

Coq est principalement codé en OCaml. Coq et OCaml sont des langages de programmations partageant d'important traits communs : ils sont tout deux du paradigme fonctionnel et sont statiquement typés. L'utilisation d'OCaml permet d'apporter des garanties sur la validité du compilateur Coq, et le fait que les deux langages soient proche facilite le développement de Coq.

• Écriture de compilateurs :

OCaml est particulièrement adapté pour l'écriture de compilateurs. Coqdoc peut être considéré comme un compilateur car il passe un fichier en représentation abstraite, procède à une évaluation et génère un document prêt à être utilisé. Le typage fort de OCaml, le haut niveau d'abstraction et l'aspect fonctionnel du langage facilite grandement l'écriture de compilateurs.

• Limitation des dépendances, et facilité d'intégration :

Une raison plus pragmatique est également que pour faciliter la gestion du projet, rajouter des dépendances à d'autres logiciels (par exemple, d'autres compilateurs de langage) n'est pas une bonne chose, tant pour la portabilité que l'évolution de la suite d'outils Coq. Choisir OCaml et les outils qui lui sont liés facilitent le processus d'intégration de Coqdoc au sein de Coq

3.2.2 Conception de l'architecture du logiciel

Coqdoc se doit d'être extensible. Pour cette raison, nous avons dû apporter une attention particulière sur ce point lors de la conception de l'architecture logicielle. Le diagramme figure 3.3 montre l'architecture simplifiée de Coqdoc.

Nous résumons les différentes étapes d'une compilation effectuée par Coqdoc :

- 1. Lecture d'un ou plusieurs fichiers d'entrée
- 2. A partir de ces fichiers une analyse syntaxique est effectuée. Ils sont alors représentés de manière abstraite, ceci afin de s'affranchir de la structure linéaire des fichiers d'entrée, et de faciliter les différentes phases de traitement.
- 3. La phase d'évaluation permet d'obtenir la représentation finale des fichiers d'entrée : les commandes entrées dans Coqdoc (l'ajout de symboles par exemple) sont évaluées, tandis que le code sera annoté et mis en forme.
- 4. Un des choix suivant est de sauvegarder cette représentation finale sous forme de Vdoc : c'est un format de fichier qui détaille la représentation abstraite des documents traités. Un fichier Vdoc peut ainsi être relu par Coqdoc pour générer plusieurs types de documentation, sans avoir à réévaluer le fichier. Cela facilite la portabilité des documents, tout en permettant à l'utilisateur de faire des ajustements plus fins concernant la documentation générée (puisque l'on se situe après l'évaluation, le code est par exemple déjà annoté pour permettre la coloration syntaxique)
- 5. L'autre choix est de générer un ou plusieurs documents finaux. On utilise pour cela un module d'impression, qui est en mesure de générer différents types de documentation. Ce module d'impression est paramétré par des "spécifications", qui détaillent le format de sortie des documents finaux. En effet, le module d'impression attend un ensemble de fonctions qui lui permettent de générer un document final. Il est ainsi facilement extensible, car pour rajouter un format de sortie, il suffit de donner sa spécification au module d'impression.

Les sections suivantes détaillent chacune des étapes de la compilation d'un document par Coqdoc.

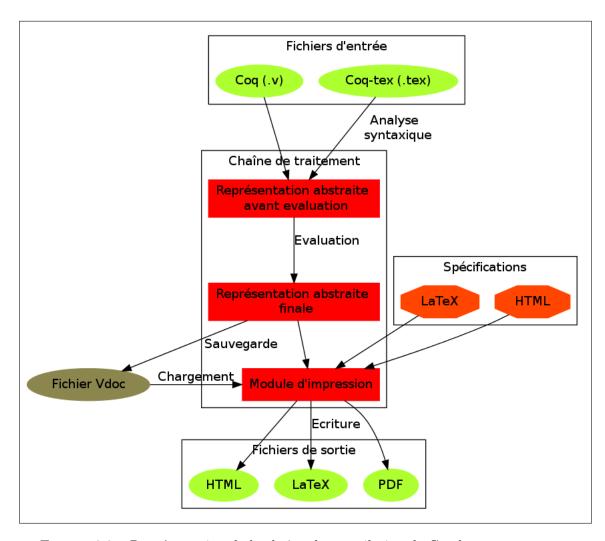


Figure 3.3 – Représentation de la chaîne de compilation de Coqdoc

Listing 3.2 – Fichier d'exemple Coq

```
(** * Fichier d'exemple Coq
Cet exemple nous accompagne tout au long du traitement

- Ceci est une liste
- de deux éléments avec une _emphase_

*)

(* Nous definissons deux variables *)
Parameter maVariable : Set.
Parameter autreVariable : Set.
```

3.2.3 Traitement du langage d'entrée

Cette section détaille les différentes phases d'analyse pour traiter le langage d'entrée de Coqdoc. Nous expliquons tout d'abord les méthodes pour effectuer une analyse syntaxique, puis nous détaillons chaque phase de traitement du langage. Pour expliquer plus facilement le traitement du langage d'entrée, nous prenons un exemple fil rouge qui accompagnera notre explication de la chaîne de traitement. Le listing 3.2 montre le fichier d'entrée donné à Coqdoc.

Traitement du langage

Le traitement d'un langage se fait en plusieurs phases logiques. Nous rappelons brièvement celles-ci :

Analyse lexicale:

La première étape est l'analyse lexicale. Cette phase vise à décomposer le document d'entrée en entités logiques, facilitant le traitement des données par la suite.

Analyse syntaxique:

La deuxième étape du traitement d'un langage est l'analyse syntaxique. Celle-ci vise à fournir une représentation de plus haut niveau pour la suite de la chaîne de traitement. L'analyseur lexical génère un ensemble d'entités, que l'analyseur syntaxique regroupera en structures de données plus riches.

Arbre de syntaxe concrète :

L'analyse syntaxique donne souvent lieu à la génération d'un arbre de syntaxe concrète. Cet arbre est une représentation intermédiaire entre le document d'entrée et l'arbre de syntaxe abstraite, qui lui représente la structure de donnée sur laquelle les traitements sont appliqués. La différence principale entre ces deux types d'arbres est qu'un arbre de syn-

taxe concrète est beaucoup plus proche du document source, est a une structure de moins haut niveau (plus proche du document source) que l'AST. Cela permet ainsi d'effectuer la transformation inverse, pour revenir à un document très proche du document source.

Arbre de syntaxe abstraite:

L'arbre de syntaxe abstraite est la représentation choisie pour appliquer des traitements sur le document d'entrée. Le haut niveau d'abstraction de cette structure de donnée permet de facilement modifier ses différent éléments, ceci afin de pouvoir effectuer une traduction simple vers la représentation finale, et générer le document de sortie.

Découpage logique du document

La première phase de traitement du document est un découpage logique en phrases de différents types : la documentation, le code et les commentaires. Ceci est fait selon les délimiteurs respectifs de la documentation et des commentaires. Tout ce qui n'est pas contenu entre ces délimiteurs est considéré comme du code.

Chaque élément de code est ensuite découpé en phrases. Ce découpage est fait selon le fait que chaque phrase Coq se termine par un point. Cela permet de simplifier le traitement sur chaque instruction du fichier d'entrée. A la fin de cette phase de traitement, nous avons donc un ensemble de phrases, chacune appartenant à l'un des types suivants

- De la Documentation sous forme de chaînes de caractères
- Des commentaires sous forme de chaînes de caractères
- Du code sous forme de chaînes de caractères, chacune de ces chaînes étant terminées par un point.

L'exemple figure 3.4 illustre la représentation de notre fichier après cette première phase de traitement. Chaque noeud représente un élément logique de notre documentation, le contenu de ce noeud étant les chaînes de caractères stockées dans le noeud de l'arbre de syntaxe abstrait.

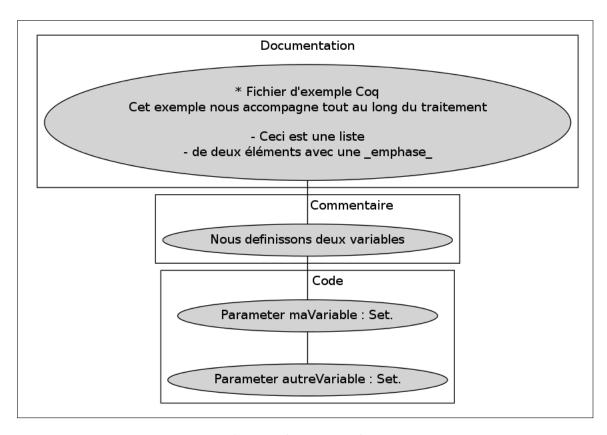


Figure 3.4 – Première représentation abstraite

Analyse de la documentation

La deuxième étape consiste ensuite au traitement de la documentation. Chaque élément du type documentation est donc analysé une seconde fois, ceci afin d'effectuer une séparation des différents éléments logiques de la documentation. Après l'analyse, cette documentation est représentée sous la forme d'un arbre qui représente la structure hiérarchique des éléments de mise en forme.

La liste suivante détaille différents types de noeud dans notre documentation :

- Éléments finaux : (contiennent des chaînes de caractère ou rien)
 - · Titre
 - · Règle horizontale
 - · Notation : notations spéciales pour dépendant du format de sortie
 - · Code Verbatim : code à imprimer dans la documentation
 - · Contenu : représente les chaînes de caractère simples
- Éléments récursifs : (contiennent des éléments de documentation)
 - · Listes : une liste contient soit d'autres listes, soit des éléments de documentation
 - · Emphase : l'emphase doit pouvoir mettre en valeur des éléments de la documentation (par exemple, des éléments d'une liste ou du code verbatim)
- Éléments à évaluer : (seront supprimés après la phase d'évaluation)
 - · Ajout de règles de notation
 - · Suppression de règles de notation
 - Commandes: Un ajout du nouveau Coqdoc est la gestion de commandes plus poussées dans le fichier d'entrée. Celles-ci seront remplacés par des noeuds de documentation après la phase d'évaluation

Après application de la transformation, la documentation est transformée d'une chaîne de caractères à une hiérarchie d'éléments décrivant le contenu. La figure 3.5 détaille par exemple la hiérarchie obtenue pour la documentation après traitement de celle-ci

3.2.4 Interactions avec l'interprète

Pour pouvoir effectuer la mise en forme des différentes sections de code, deux approches étaient possibles :

• Effectuer une analyse lexicale et syntaxique du code, pour en obtenir les différents éléments logique, et coder un *pretty-printer* pour imprimer le code de manière lisible. Cela impose de traiter un langage très complexe (composé d'un nombre important de mots clefs et de constructions syntaxiques), et de complexifier de manière importante le logiciel. Écrire un

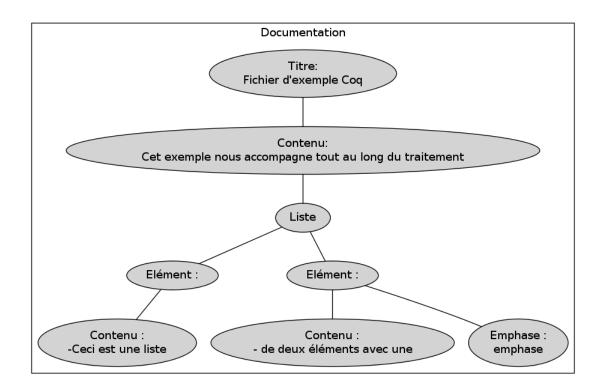


Figure 3.5 – Traitement de la documentation

- module d'analyse du langage Coq insère également de la redondance dans le projet, puisque le compilateur Coq effectue déjà cette analyse. Cette approche était celle de l'ancien Coqdoc.
- Réutiliser l'interprète pour nous donner des informations sur du code. A partir d'un protocole existant, nous envoyons des séquences de code, et l'interprète est en mesure de renvoyer une version imprimée de manière jolie, avec les bonnes annotations syntaxique. Parce que ce protocole fait l'interface entre l'interprète et d'autres logiciels, il est facilement extensible, car nous avons accès à tous les éléments du compilateur. La duplication de code est donc inexistante avec cette approche, et l'extension du protocole d'interaction entre l'interprète et les logiciels qui l'utilisent est bénéfique pour tous ces logiciels.

C'est la seconde approche qui a été choisie : elle permet de réutiliser l'existant tout en facilitant une extension de ces interactions à nos besoin

Protocole d'interaction

Le protocole d'interaction de l'interprète est une communication sous forme de XML, ce qui permet de l'utiliser avec une grande variété d'outils. La liste suivante présente les requêtes de ce protocole :

- evars, goals, hints, ...: Commandes utilisées pour les preuves. Coqdoc n'en aura pas l'utilité.
- inloadpath : permet de savoir si un dossier est dans le chemin de chargement de Coq
- interp : Prends une phrase Coq sous forme de chaîne, et effectue l'interprétation de cette phrase.
- rewind : permet de revenir en arrière dans l'exécution
- status : donne des informations sur le status de l'interprète
- quit : ferme le protocole d'interaction

3.2.5 Extension du protocole d'interaction

Avant de pouvoir être utilisé sous cette forme, le protocole d'interaction a besoin d'être étendu pour pouvoir annoter du code, et situer les différents identifiants.

Deux commandes ont donc été développés afin de répondre aux besoins de Coqdoc

• locate : prends un identifiant sous forme de chaîne de caractères, et renvoie sa localisation (dans quel fichier, module, et sous module). Cette commande doit permettre de pouvoir, a partir d'informations obtenues sur le code, permettre de reconnaître les identifiant, et ainsi pouvoir générer des liens vers l'endroit où ils sont déclarés dans la documentation produite.

• prettyprint : Cette commande prends une chaîne de caractère, et renvoie une version structurée selon les différents éléments la composant : mots clefs, identifiants, nombres, etc Elle doit de plus donner les informations de mise en forme du code (par exemple, l'indentation).

Tandis que le développement de la commande locate a été rapide, le développement de la commande prettyprint a été compliqué car il a fallu combler un manque du logiciel Coq.

L'approche idéale pour effectuer l'annotation serait d'utiliser l'arbre de syntaxe concrète de Coq. Comme expliqué dans la section 3.2.3, cet arbre de syntaxe doit théoriquement être en mesure de donner les bonnes annotations puisqu'il possède encore beaucoup d'informations d'ordre syntaxique. Son niveau d'abstraction est théoriquement adapté à nos besoins, car il représente encore fidèlement le code source que Coqdoc cherche à traiter. Cependant cet arbre de syntaxe concrète n'existe pas dans Coq, qui fait une traduction directement vers une représentation de haut niveau.

L'approche la plus efficace aurait été de changer la chaîne de traitement de Coq pour pouvoir y insérer cet arbre de syntaxe concrète, mais cela impose une importante réflexion et beaucoup de changement de code. Au vu de la durée du projet, cette solution a été rejetée immédiatement car elle était trop complexe pour le temps disponible.

Pour implémenter cette commande, il faut donc se reposer sur l'arbre de syntaxe abstraite, qui possède une représentation de très haut niveau, et dont l'annotation est complexe.

Un des mécanismes de traduction de l'arbre de syntaxe vers des chaînes de caractères est le *pretty-printer* de Coqdoc. Son rôle est d'imprimer de manière correctement indentée l'arbre de syntaxe. Instrumenter le code du *pretty-printer* à nos besoins nous permettrait ainsi de profiter de cette étape de traduction de l'arbre de syntaxe vers le texte. L'objectif est donc de modifier ce module de Coq pour, lors de la traduction, conserver les types de l'arbre, et ainsi pouvoir effectuer facilement une coloration syntaxique du coté de Coqdoc.

La traduction du module d'impression de Coq se fait directement vers des chaînes de caractères. Ceci est problématique car cela enlève toutes les informations sémantiques qui serviraient à Coqdoc. La première approche que nous avons adopté était donc de modifier ce module d'impression, pour qu'au lieu de traduire vers des chaînes de caractères, il effectue une traduction vers un arbre de syntaxe allégé, chaque noeud ayant pour contenu les chaînes de caractère issues de l'impression.

La première tentative de réécriture du module d'impression consistait en la transformation du code de façon à accueillir des types génériques. Cela

permet d'avoir :

- L'ancien comportement du module d'impression, sans modifier le code l'utilisant
- Un nouveau comportement permettant la traduction vers la structure de donnée adaptée pour Coqdoc

Cette approche impose de redéfinir un ensemble conséquent de types : il faut reprendre les types de l'arbre de syntaxe abstraite pour créer une version de cet arbre avec des chaînes de caractère contenant le résultat de l'impression des noeuds. Il faut également réécrire une partie importante du module d'impression afin d'accueillir ces deux types (le type préexistant et celui que nous créons). La figure 3.6 présente l'inclusion du module au sein de l'impression de Coq. Cet arbre annoté correspond à ce que l'on désire obtenir du coté Coqdoc. Cette structure contient toutes les informations nécessaires pour effectuer l'impression du code, tout en conservant la sémantique nécessaire pour effectuer des traitements dessus.

Cette méthode de traduction ne fut pas terminée pour des raisons de temps. La phase de réécriture que j'ai entreprise était très coûteuse en temps, et nous n'avions pas les garanties qu'à l'issue de cette réécriture le résultat serait acceptable. En effet, même si cette réécriture avait put être achevée à temps, la mise en place de tests et la correction du module écrit aurait également pris beaucoup de temps. Face aux objectifs du stage et face aux impératifs de temps, nous avons donc adopté une méthode dont la qualité des résultats serait moindre, mais dont le développement et la validation seraient plus rapide.

Cette deuxième approche instrumente toujours le code du module d'impression afin d'obtenir une version de l'arbre annotée. Cependant, plutôt que de procéder à une réécriture complète du type de l'arbre, nous modifions la phase d'impression de cet arbre. L'impression de l'arbre de syntaxe passe par un ensemble réduit de fonctions. En modifiant ces fonctions à nos besoin, nous pouvons ainsi, selon le contexte, sélectionner le mode d'impression. Soit l'impression par défaut est utilisée, soit, lors de l'interaction avec Coqdoc, nous utilisons le mode d'impression modifié.

Comme décrit précédemment, l'interaction entre l'interprète et Coqdoc se fait au moyen d'un protocole XML. En réécrivant les fonctions d'impression, au lieu de générer la version par défaut du code, nous générons une version annotée par XML : chaque noeud appelant les fonctions d'impression est ainsi inclus dans des balises XML portant le type du noeud. La figure 3.7 schématise cette traduction. Le module d'impression peut ainsi générer au choix, selon la destination une version annotée ou pas du résultat de l'impression. L'implémentation et l'intégration d'une telle fonctionnalité fut rapide et facile à tester, et a posteriori, c'était le meilleur compromis entre le temps et la qualité de l'implémentation.

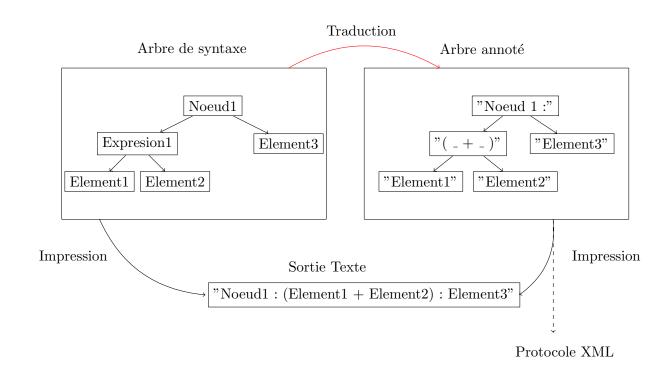


Figure 3.6 – Traduction de l'arbre de syntaxe abstraite




Figure 3.7 – Traduction vers une mise en forme XML

Du coté Coqdoc, il est facile de gérer ce type de messages à partir du XML. En effet, en effectuant une seconde passe sur le contenu du message, nous obtenons une hiérarchie que nous retraduisons dans une version adaptée à nos besoins. Cette nouvelle version comporte les types qui nous intéressent du point de vue Coqdoc, avec une sémantique du code très proche de nos objectifs.

3.2.6 Traitement du code annoté

Une fois la hiérarchie du code constituée, et son contenu correctement indenté par l'interprète de Coq, il est facile d'appliquer des traitements à ce code.

Les traitements à effectuer sur une portion de code sont les suivants :

• Coloration syntaxique:

Pour chaque type de noeud de l'arbre (correspondant à une expression), il faut décider à quel type de coloration il appartient (mot clef, identifiant, littéral, etc...).

• Règles de notations :

L'utilisateur peut définir des règles de traductions concernant certaines "phrases" de code, et Coqdoc doit les appliquer, plus celles déjà présentes par défaut.

• Gestion des identifiants :

Coqdoc doit être capable de reconnaître les identifiants afin de pouvoir y appliquer des traitements supplémentaires.

Les contraintes pour le système de traduction de code sont donc d'avoir un mécanisme extensible à l'exécution (pour pouvoir rajouter des règles facilement), et d'avoir une possibilité de chaîner des traitements, certaines expressions pouvant être la cible de plusieurs traitements.

Le patron de conception chaîne de responsabilité

L'approche choisie pour répondre à cette problématique est l'utilisation du patron de conception chaîne de responsabilité. Ce patron considère d'un coté un ensemble de commandes (nos règles), et de l'autre coté la donnée sur laquelle les commandes doivent être appliquées.

Chaque commande est en fait une fonction qui gère les deux cas suivants :

- Si la donnée est du bon type, la commande applique le traitement.
- Sinon, elle appelle la commande suivante dans la hiérarchie.

Une commande transmet ainsi le contrôle à la commande suivante. Quand il n'y a plus de commandes à appliquer, on considère que la donnée est traitée, et elle est prête à être imprimée.

Ainsi, chaque donnée peut bénéficier d'une série de traitements. Ce qu'il manque est la gestion de l'extensibilité des traitements.

OCaml est un outil qui se prête très bien à ce patron de conception, et il fut facile d'ajouter un aspect extensible à ce patron. Une fonction add_rule a ainsi été crée pour cela. Elle attend une autre fonction (décrivant le traitement), et un type (sur lequel le traitement s'applique). Le listing 3.3 décrit l'ajout d'une règle sur le code.

Listing 3.3 – Exemple d'ajout de règle

```
add_rule C_Id

(function fallback args -> match args with

AString id -> Ident id

| _ -> fallback args)
```

La ligne 1 appelle tout d'abord la fonction add_rule avec le type C_Id qui correspond au types des identifiants dans le code à traiter. La règle sera donc appliquée uniquement à ce type d'identifiants. Ensuite, sur la ligne 2 on définit la fonction qui décrit la commande à appliquer (le mot clefs function) Cette commande prends deux arguments : args qui correspond aux valeurs contenues dans le type C_Id (le nom de l'identifiant par exemple), et fallback, qui est la règle suivante à appliquer.

Ainsi, cette commande s'applique sur tout les noeuds de type C_Id, et s'ils contiennent une chaîne de caractère correspondant à leur nom, alors ils deviennent du type Ident, pour être imprimés avec la bonne coloration. Sinon, la fonction fallback est appelée, pour appliquer le reste des traitement sur le type C_Id.

Types décrivant le code

Comme expliqué précédemment, le type fourni par l'interprète est trop riche pour notre utilisation. Nous procédons donc à une phrase de traduction vers un type plus adapté à nos attentes, décrivant uniquement les différents types de constructions du langage Coq. La liste suivante détaille ces types :

- Keyword : ce type décrit les différents mots clefs du langage Coq
- Ident : ce type décrit les identifiants
- Literal : tout ce qui est valeurs littérales (entiers, chaînes de caractères, etc ...)
- Tactic : ce type décrit des constructions particulière au langage Coq qui sont les tactiques, utilisées dans les preuves
- Symbol : On définit également des règles spécifiques pour les symboles imprimés(tel que ←)
- NoFormat : Enfin, tout ce qui n'a pas de règle particulière, ce type ne recevra pas de mise en forme particulière lors de l'impression.

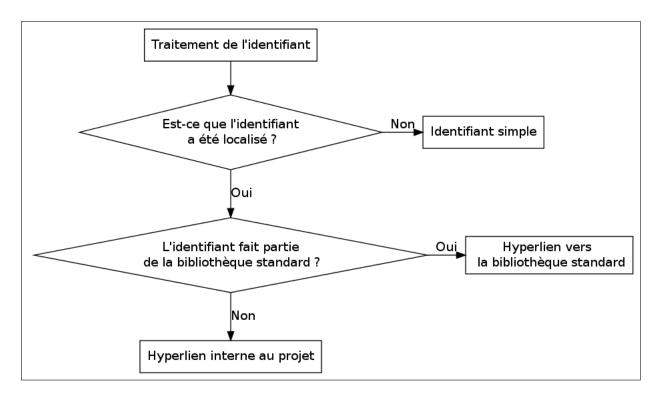


FIGURE 3.8 – Chaîne de traitement des identifiants

On est ainsi en mesure d'obtenir une coloration syntaxique simple à appliquer.

De la même manière, il est facile d'ajouter des règles de traductions qui s'appliqueront à ces éléments de code.

3.2.7 Gestion des identifiants

Grâces aux règles de traduction du code, on peut facilement insérer une règle pour la gestion des identifiants dans la chaîne de traitement. La chaîne de traitement lorsqu'un identifiant est rencontré est décrite dans la figure 3.8.

Sur chaque identifiant, la commande locate a été appliquée. Si l'identifiant est reconnu, on obtient alors son "nom" absolu, qui détaille le fichier et les modules dans lequel il est inclus. On est ensuite en mesure de vérifier s'il appartient bien au projet courant (on générera ainsi un lien hypertexte), s'il appartient à la bibliothèque standard (dans ce cas là, on génère un lien vers la documentation de cette bibliothèque), et sinon, il n'appartient à aucune bibliothèque, et dans ce cas là on ne génère rien.

3.2.8 Génération des documents finaux

L'étape finale de la chaîne de compilation est la génération de documents finaux.

Pour gérer cette diversité des formats de sortie, nous avons préalablement défini un type de documentation générique, donc les règles d'impression dépendent du format de sortie.

Nous avons donc, comme expliqué précédemment, des spécifications qui correspondent à chaque type de document de sortie, et un module central qui se charge d'utiliser ces spécifications dans l'ordre adapté pour la génération des documents. Ces spécifications sont en fait des fonctions de traductions, chaque module décrivant un type particulier de fichier de sortie. La liste suivante détaille les différentes fonctions attendues :

- header : Cette fonction est utilisée pour générer l'en-tête du fichier de sortie.
- footer : De même, celle ci génère la fin du fichier.
- doc : Cette fonction est utilisée pour la traduction des règles de documentation en texte. Pour chaque type dans la documentation, un traitement particulier est appliqué par le module de spécifications
- code : De même, cette fonction s'occupe de la traduction du code
- indent : S'occupe de l'indentation du code, certains formats de fichiers ayant des règles particulières pour celle-ci
- newline : Également, certains formats ont des règles particulières pour les retours à la ligne
- index : Cette fonction s'occupe de générer l'index des symboles d'un fichier de documentation. Cela offre un accès rapide au programmeur s'il recherche la définition de certains symboles
- file_index : Permet de générer l'index des fichiers d'un projet. Cela permet au programmeur d'accéder rapidement à un autre fichier du projet.
- begindoc, enddoc, begincode, endcode : Ces fonctions s'occupent de gérer le contexte de la documentation : si on est en train de générer de la documentation ou du code.

La dernière partie à gérer est la décoration des documents de sortie : afin d'obtenir un produit bien présenté, il est également nécessaire d'inclure des fichiers de style avec la documentation générée. Pour cela, nous réutilisons les fichiers de style du Coqdoc précédent pour la sortie HTML et LaTeX.

3.2.9 Extension de Coqdoc pour Coq-tex

Cette section détaille l'extension de Coqdoc afin de pouvoir accueillir les fonctionnalités de Coq-tex. Cela vise à mettre en évidence la simplicité d'extension du logiciel pour l'adapter à des taches annexes.

Traitement du langage

La première partie est l'ajout d'un analyseur syntaxique pour gérer le langage spécial de Coq-tex. Celui est très simple, puisqu'il à juste à reconnaître les environnements example, example* et eval. Ce qui est contenu dans ces environnements est du code, le reste est de la documentation². Pour chaque type d'environnement, nous créons effectuons une traduction vers le type commande lors du traitement du langage, qui seront ainsi traitées lors de la phase d'évaluation.

Évaluation du code

Chacune de ces requêtes sera ainsi évaluée, et l'interaction sera faite avec l'interprète pour traiter le code. Après cette évaluation, nous avons un type code, qui sera inclut dans la documentation.

Ajout d'options

Enfin, nous rajoutons les options de Coq-tex à celles de Coqdoc, afin de pouvoir copier le comportement de l'ancien Coq-tex. Nous appliquons également une restriction sur le type de documents générés, puisque, à partir d'un document LaTeX, nous désirons obtenir un autre document LaTeX avec le traitement du code source effectué.

^{2.} Cette documentation ne sera pas mise en forme, et aucun traitement ne lui sera appliqué, l'objectif étant de la copier dans le fichier de sortie

3.3 Interprétation et critique des résultats

3.3.1 Version préliminaire de Coqdoc stable

À l'issue de ce stage, nous avons une version préliminaire de Coqdoc fonctionnelle. L'ensemble des caractéristiques principales du logiciel sont implémentées, et la chaîne de traitement est bien définie et finalisée. Le logiciel est en mesure de générer des documents dans plusieurs formats, et gère les formats d'entrée de Coqdoc et de Coq-tex.

Nous parlons d'une version préliminaire car le logiciel n'a pas pu être finalisé. Il reste encore quelques développements afin d'en faire un logiciel prêt à être publié dans le projet Coq. Les développements qui restent à faire sont les suivants :

- Gestion des options : des options du précédent logiciel ne sont pas encore gérées. Cela demandera quelques développements dont la durée est jugée très faible, ces options étant facile à insérer dans le logiciel.
- Gestion des erreurs : Un autre aspect de la finition de Coqdoc est la reprise et la gestion des erreurs, pour pouvoir fournir à l'utilisateur un compréhension claire du comportement de Coqdoc.

Ces deux développements sont d'importance mineure et sont facile à implémenter pour avoir un logiciel complètement finalisé. Je pense que l'absence de finalisation du logiciel est due à l'importante phase d'expérimentations faite au cours de ce stage, qui a été très coûteuse en temps. La section 6.4 montre les résultats obtenus à l'issue de ce stage, qui démontrent l'utilisabilité du logiciel. J'estime que le temps manquant pour finir ce logiciel était d'approximativement d'un mois, à l'issue duquel Coqdoc aurait pu être pleinement intégré.

Cette version préliminaire offre déjà des améliorations par rapport à l'ancien Coqdoc. Tout d'abord, le nouveau logiciel n'utilise plus les fichiers .glob pour traiter les identifiants, étant capable de fournir encore plus d'informations sur ceux ci que l'ancien logiciel.

Également, la gestion des notations a été enrichie pour pouvoir transformer les notations définies par l'utilisateur en une commande spécifique au format de sortie.

3.3.2 Extensibilité du logiciel

L'autre objectif annoncé de ce stage était de réaliser un logiciel extensible. Nous considérons cet objectif atteint, la section 3.2.9 qui détaille l'ajout de Coq-tex dans Coqdoc mettant en évidence qu'il est très facile de rajouter des fonctionnalités à ce logiciel.

Pour les fichiers d'entrée, il est facile de rajouter un format de fichier accepté par Coq, juste en ajoutant un module de traitement du langage. Ce module doit juste effectuer la traduction du langage source vers la représentation intermédiaire de Coq. Cette représentation intermédiaire est très facilement extensible si nécessaire pour correspondre aux besoins de l'utilisateur

La phase d'évaluation, quant à elle, s'étend également facilement, en acceptant des commandes utilisateur issues du fichier d'entrée. Le patron de conception chaîne de contrôle rend également très simple l'ajout de nouvelles règles de traitement sur le code.

Enfin, pour ce qui est de la génération de documents, le rajout d'un nouveau module spécifiant un nouveau format de documentation est simple à mettre en place.

3.3.3 Perspectives d'évolution du logiciel

La conception du logiciel permet de proposer un grand nombre de perspectives d'évolution, et ce, à plusieurs niveaux. La liste suivante détailles les principales idées énoncées au cours de ce stage, et avance d'autre possibilités.

- Tutoriaux interactifs: grâce à l'utilisation de Javascript, il serait possible de construire des documents interactifs. L'utilisateur pourrait ainsi apprendre à se servir de Coq, ou rejouer pas à pas des démonstrations de preuves.
- Rédaction de livres sur Coq : avec quelques ajustement, Coqdoc ferait un bon support pour la rédaction de livres dont le sujet est Coq. Grâce à l'extensibilité sur les formats de sortie, il serait possible de générer de tels documents dans une grande variété de formats (notamment des formats e-book).

Toutes ces idées reposent autour d'une interaction riche avec l'interprète, et d'un modèle d'éditions à travers des documents structurés, ce que fournit Cogdoc.

Protocole d'interaction

Concernant le protocole d'interaction, il constitue une brique centrale dans divers logiciel gravitant autour du compilateur Coq. On peut par exemple citer CoqIDE, qui est à l'origine de ce protocole. L'extension de ce protocole d'interaction est simple, et tous les outils qui l'utilisent peuvent en bénéficier.

Ce protocole d'interaction ne se limite pas forcément à la génération de documents, et il serait également possible de mettre en place des outils dédiés à l'analyse des performances, les tests unitaires ou encore la réécriture de code source.

Chapitre 4

Conclusion générale

Ce stage fut pour moi une réussite sur de nombreux plans. J'ai pris plaisir à travailler au sein de l'équipe πr^2 , qui a su m'accueillir chaleureusement, et m'offrir un très bon encadrement au cours de ces 5 mois.

Tout d'abord, concernant le traitement du langage d'entrée, cela m'a permis de valider mes acquis en analyse syntaxique et lexicale, et plus généralement en traitement du langage. Cette première partie est implémentée et fonctionnelle et, elle est facilement extensible pour de nouveaux formats d'entrée.

L'interaction avec l'interprète m'a mis face à des difficultés auxquelles j'ai su répondre. En prenant en compte les impératifs de temps et la complexité du logiciel, j'ai été amené à choisir une approche donnant des résultats satisfaisant pour le projet. La phase d'évaluation autour de cette interaction m'a permis de concevoir une architecture de traitement à la fois générique et facilement extensible, tout en offrant des garanties de solidité pour le programmeur.

Enfin, la génération de documents m'a amené à structurer une représentation intermédiaire dans Coqdoc de façon à ce qu'il soit facile de générer plusieurs types de documents de sortie, chacun avec leurs spécificités. Cette représentation est ainsi capable de s'abstraire des particularités de chaque format de sortie.

Ce stage m'a permis de valider un nombre important de compétences enseignées à l'Epita. Tout d'abord, les aspects techniques, mes compétences en programmation et en développement d'un projet ayant été mises à l'épreuve sur une application du monde réel.

Un autre aspect est celui de la conception du logiciel, notamment le découpage en briques architecturales et l'attention porté à l'extensibilité. A travers le travail sur Coqdoc, j'ai pu valider de telles compétences. Enfin, j'ai pu découvrir les différents thèmes de recherche au sein de l'équipe πr^2 et plus largement au sein du laboratoire PPS.

Chapitre 5

Webographie

- EPITA www.epita.fr
- INRIA www.inria.fr
- LRDE www.lrde.epita.fr
- Langage Ocaml
- www.caml.inria.fr
 PPS

www.pps.univ-paris-diderot.fr

- Projet Coq www.coq.inria.fr
- πr^2 http://www.pps.univ-paris-diderot.fr/pi.r2/

Chapitre 6

Annexes

6.1 Sommaire des Annexes

Contents		
6.1	Sommaire des Annexes	
6.2	Documentation sur l'entreprise 4	9
	6.2.1 Les membres du conseil d'administration de l'INRIA 4	9
6.3	Documentation sur le matériel/les logiciels 5	1
	6.3.1 $$ Table de traduction des symboles dans Coqdoc $$. $$ 5	1
6.4	Résultats bruts 5	2

6.2 Documentation sur l'entreprise

6.2.1 Les membres du conseil d'administration de l'INRIA

Le tableau suivant présente les membres actuels (15 janvier 2013) du conseil d'administration de l'INRIA :

Président : Michel Cosnard, président directeur général de l'INRIA **Membre de droit** : Alain Fuchs, président directeur général du CNRS **Représentants de l'état** :

Marc Bellœil	Chargé de mission, département Organismes
	spécialisés, DGRI (Recherche)
Fabien Terraillot	Chef du bureau du logiciel, DGCIS (Industrie)
François Pouget	Chef du bureau 3 (MIRES), direction du Budget
	(Budget)
Éric Grégoire	Conseiller scientifique de formation, DGESIP
	(Enseignement supérieur)
Christine Marteau	Responsable du pôle Télécommunications, DGA
	(Défense)
Pascal le Deuff	Sous-directeur des échanges scientifiques et de
	la recherche (Affaires étrangères)
Cécile Dubarry	Chef du service des technologies de l'in-
	formation et de la communication, DGCIS
	(Télécommunications)

Membres nommés :

Jean-Luc Beylat	Président d'Alcatel-Lucent Bell Labs France
Bernard Jarry-Lacombe	Secrétaire national CFDT cadres
Marie-Noëlle Jégo-Laveissière	Directrice recherche et développement, Orange
	Labs
Gilles Le Calvez	Directeur R&D du Groupe Valeo
Brigitte Plateau	Administrateur général INP Grenoble
Luc Pabœuf	Président du CESR d'Aquitaine
Laure Reinhart	Directrice générale déléguée, OSEO et OSEO In-
	novation
Gérard Roucairol	Président de l'association Ter@tec

Membres élus : Représentants des personnels scientifiques

Serge Steer	Directeur de recherche, Inria Paris-		
	Rocquencourt		
Jocelyne Erhel	Directrice de recherche, Inria Rennes - Bretagne		
	Atlantique		
Lisette Calderan	Ingénieur de recherche, Inria Siège		
Laurent Pierron	Ingénieur de recherche, Inria Nancy - Grand Est		

Voix consultatives:

Malika Moha	Contrôleur général
Marie-Laure Inisan-Ehret	Agent comptable
Chris Hankin	Président du conseil scientifique
Antoine Petit	Directeur général adjoint

6.3 Documentation sur le matériel/les logiciels

6.3.1 Table de traduction des symboles dans Coqdoc

Le symbole	est traduit en
->	\rightarrow
<-	\leftarrow
*	×
<=	<u> </u>
>=	≤≥⇒
=>	\Rightarrow
<> <->	\neq
<->	\leftrightarrow
I -	
\/	\wedge
/\	V
~	П

6.4 Résultats bruts

Les images qui suivent donnent un exemple de documents générés par Coqdoc.

Links

```
Various checks for cogdoc
    · symbols should not be inlined in string g
    • links to both kinds of notations in a' should work to the right notation
    • with utf8 option, forall must be unicode
    . splitting between symbols and ident should be correct in a' and c
    . ".." should be rendered correctly
    • test emphasis!
Require Import String.
Definition g := "dfjkh" "sdfhj forall <> * ~ "%string.
Definition a (b : nat) := b.
Definition f := forall C : Prop, C.
Notation "n ++ m" := (plus n m).
Notation "n ++ m" := (mult n m).
Notation "n ** m" := (plus n m) (at level 60).
Notation "n \triangle m" := (plus n m) (at level 60).
Notation "n '_' ++ 'x' m" := (\underline{plus} n m) (at level 3).
Inductive eq (A : Type) (x : A) : A-> Prop eq_refl : x = x :> A where "x = y :> A" := (@eq A x y) : type_scope.
Definition eq0 := 0 = 0 :> nat.
Notation "( x # y ; ... ; z)" := (pair .. (pair x y) ... z).
Definition b_{\alpha} := ((0 \# 0; 0), 0 \times 0).
Notation localh := locala.
Section test.
    Variables b' b2 : nat.
    Notation "n + m" := (n \triangle m) : my\_scope.
    Delimit Scope my_scope
with my.
    Notation l := 0.
    Definition \alpha \cdot = (0 + 1)mv
```

Figure 6.1 – Exemple de rendu en HTML

Chapter 1

Links

Various checks for coqdoc

- symbols should not be inlined in string g
- links to both kinds of notations in a' should work to the right notation
- with utf8 option, for all must be unicode
- $\bullet\,$ splitting between symbols and ident should be correct in a' and c
- ".." should be rendered correctly
- test emphasis!

```
Require Import String. Definition g:="dfjkh""sdfhj forall <> * \~"%string. Definition a (b: nat) := b. Definition f:= forall C: Prop, C. Notation "n ++ m" := (plus n m). Notation "n ++ m" := (mult n m). Notation "n ** m" := (plus n m) (at level 60).
```

FIGURE 6.2 – Exemple de rendu en LateX